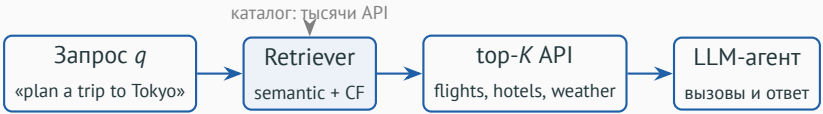
Collaborative Filtering for Tool Selection in LLM Agents

Исследовательский proposal, курс «Рекомендательные системы»

Илья Звездин Святослав Полонский Артём Туревич

Октябрь 2026

Задача и гипотезы



Почему нетривиально

- «пользователь» = запрос: почти всегда cold start
- нужны взаимодополняющие API, а топ по косинусному расстоянию дублирует функции
- разметка неполна: «не размечен» $\neq$ «не нужен»

Гипотезы

H1 CF-сигнал дополняет текстовое сходство

H2 эффект сильнее на multi-tool и новых комбинациях API

H3 на естественных запросах (ToolLens) вклад CF выше, чем на синтетике

H4 рост полноты retrieval повышает task success агента, NDCG - необязательно

Существующие работы и наш вклад

Работа	Что уже сделано
ToolLLM / ToolBench (Qin et al., ICLR'24)	16k API RapidAPI, инструкции, разметка. Агент **ToolLLaMA**: LLaMA-2-7B, SFT на траекториях ChatGPT (поиск DFSDT), retriever на BERT-base
COLT + ToolLens (Qu et al., CIKM'24)	семантика + graph CF, естественные запросы
ToolRet (Shi et al., ACL'25)	35 датасетов, 44k tools, IR-модели проседают
StableToolBench (Guo et al., ACL'24)	виртуальные API для оценки агента

Наша самостоятельная работа

- **индуктивные** CF-гибриды: новые запросы без переобучения
- контроль: **обученный** Two-Tower отделяет CF от supervised-обучения
- **3 бенчмарка**: in-domain, перенос, item cold start — *когда* CF помогает

Метод: semantic + collaborative

Item = **API endpoint**. Train-матрица $R_{it} = 1$, если API t релевантен запросу q_i.

1. **Semantic:** замороженный `bge-small-en-v1.5`, $s_{\text{sem}}(q,t) = \cos(e_q, e_t)$. Лексический бейзлайн — **BM25** по тем же описаниям API.
2. **Query-KNN CF:** у нового запроса нет строки в R (cold start), поэтому берём историю m ближайших по эмбеддингу *train*-запросов:

$$s_{\text{CF}}(q,t) = \sum_{i \in N_m(q)} w(q,q_i)\, R_{it}$$

3. **Гибрид:**

$$\boxed{s(q,t) = \alpha\, \widetilde{s}_{\text{sem}}(q,t) + (1-\alpha)\, \widetilde{s}_{\text{CF}}(q,t)}$$

4. **Co-occurrence:** жадный набор S с бонусом $\beta \max_{t' \in S} \widetilde{C}_{tt'}$, $C = R^\top R$
5. **Контроль:** Two-Tower $u_q = W_q e_q$, $v_t = W_t e_t$, BPR-loss, hard negatives

API без истории: $s_{\text{CF}} = 0$, откат к semantic (+ сглаживание по соседним API)

Данные, бейзлайны, протокол

Датасет	Запросы	Каталог	Роль
ToolBench	$\sim$126k	16 464 API	основной, G1/G2/G3
ToolLens	18 770	464 API	естественные запросы, $\approx$2.7 API/запрос
ToolRet	7 961	44 453	35 подвыборок + 209k train, cold-start API

- **Протоколы:** split по запросам, отложенные *комбинации* API, перенос с ToolBench на ToolLens
- **Бейзлайны:** Popularity, BM25, BGE
- **Метрики:** Recall@K, NDCG@K, FullCoverage@K при $K \in \{3, 5, 10, 20\}$
- **Агент:** Qwen3-4B + StableToolBench, 100–200 задач, task success

План, команда, риски

Срок	Результат и ответственный
19.11	**Илья Звездин**: данные ToolBench + ToolLens, splits, метрики. **Святослав Полонский**: Popularity, BM25, BGE
03.12	**Святослав Полонский**: KNN-CF, гибрид, перенос. **Артём Туревич**: co-occurrence, Two-Tower, абляции. **Илья Звездин**: ToolRet
09.12	**Артём Туревич**: графики, анализ ошибок, agent-пилот. **Все**: отчёт, воспроизводимость
10–11.12	**Все**: защита

Ресурсы: CF и метрики — CPU. Эмбеддинги и Two-Tower — GPU 8–16 GB (минуты). Агент — $\geq$16 GB + vLLM.

Риски: синтетичные запросы и утечки, неполная разметка, нестабильные API, сопоставление ToolRet-train.

Минимальный результат: воспроизводимое offline-сравнение BM25 / BGE / KNN-CF / гибрида на ToolBench + ToolLens с абляциями. ToolRet и агент — расширения.

https://github.com/pururus/CFTSagent/